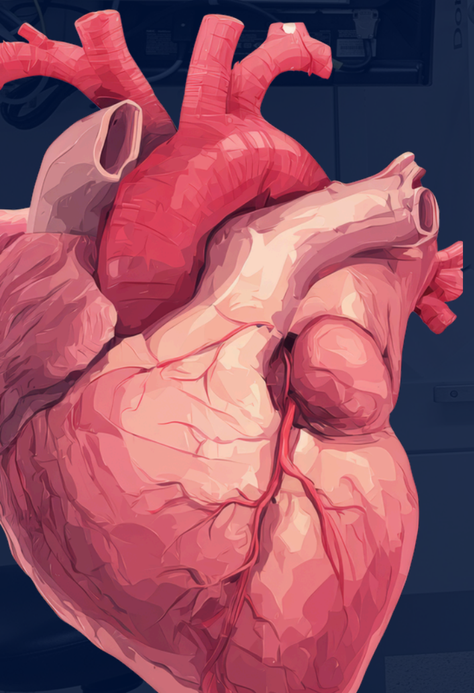
HEART ATTACK RISK PREDICTION

– Final Project Data Mining A –





ANGGOTA KELOMPOK



DANELLA CITRA ALDARENA

5003231003



MARIA IMMACULATA DYAH HITA WIDOWATI

5003231027



RUTH WAHYU SEDJATI PRIYAMBODO

5003231129

PROBLEM STATEMENT

Serangan jantung adalah salah satu penyebab utama kematian di dunia.

Deteksi dini risiko serangan jantung sangat penting untuk pencegahan dan pengobatan.

Data kesehatan individu (usia, jenis kelamin, tekanan darah, kolesterol, riwayat penyakit, dll) bisa digunakan untuk memprediksi risiko serangan jantung secara otomatis.

DESKRIPSI DATASET

Sumber : https://www.kaggle.com/datasets/sonialikhan/heart-attack-analysis-and-prediction-dataset

Fitur	Deskripsi
age	Usia individu
sex	Jenis kelamin (1 = pria, 0 = wanita)
cp	Tipe nyeri dada (1–4: typical/atypical/non-
trtbps	Tekanan darah saat istirahat (mm Hg)
chol	Kadar kolesterol (mg/dL)
fbs	Fasting blood sugar (>120 mg/dL = 1)
rest_ecg	Hasil EKG saat istirahat (0 normal, 1 ST-T
thalach	Detak jantung maksimal yang dicapai
exang	Angina saat olahraga (1 = ya, 0 = tidak)
oldpeak	Depresi ST saat olahraga
slope	Slope ST saat puncak olahraga
ca	Jumlah pembuluh darah utama (0–3)
thal	Thalassemia (tipe darah terkait penyakit

DATA PREPROCESSING

Missing Value

age	0
sex	0
cp	0
trtbps	0
chol	0
fbs	0
restecg	0
thalachh	0
exng	0
oldpeak	0
slp	0
caa	0
thall	0
output	0

Tipe Data

age	int64
sex	category
cp	category
trtbps	int64
chol	int64
fbs	category
restecg	category
thalachh	int64
exng	category
oldpeak	float64
slp	category
caa	category
thall	category
output	category

Check Outlier

	age	sex	cp	trtbps	chol
28	65	0	2	140	417
85	67	0	2	115	564
96	62	0	0	140	394
220	63	0	0	150	407
246	56	0	0	134	409

Encode Variabel

sex_1	cp_1	cp_2	cp_3	fbs_1	...	slp_1	slp_2	c
True	False	False	True	True	...	False	False	
True	False	True	False	False	...	False	False	
False	True	False	False	False	...	False	True	
True	True	False	False	False	...	False	True	
False	False	False	False	False	...	False	True	
...	...	...	...	...	...	...	...	

Normalization

age	trtbps	chol	thalachh	oldpeak
0.952197	0.763956	-0.256334	0.015443	1.087338
-1.915313	-0.092738	0.072199	1.633471	2.122573
-1.474158	-0.092738	-0.816773	0.977514	0.310912
0.180175	-0.663867	-0.198357	1.239897	-0.206705
0.290464	-0.663867	2.082050	0.583939	-0.379244

Train-Test

```
Train predictor dataset shape: (242, 22).
Train target dataset shape: (242,).
Test predictor dataset shape: (61, 22).
Test target dataset shape: (61,).
```

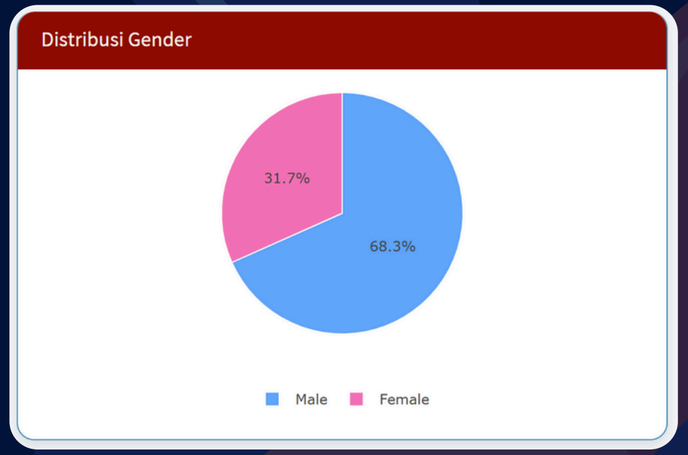
SUMMARY STATISTICS & VISUALIZATION

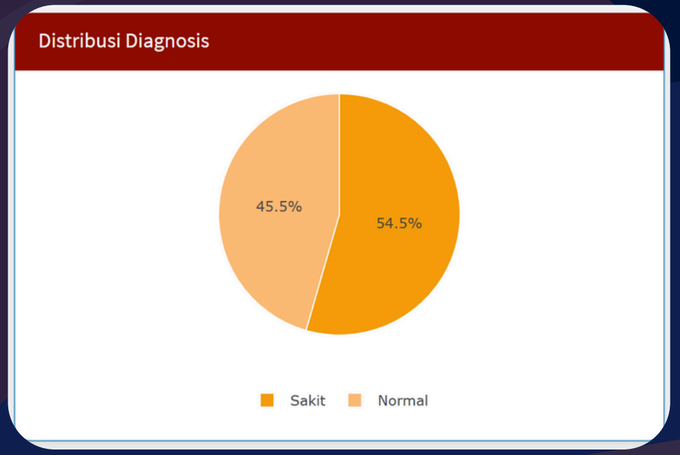
303
Total Pasien

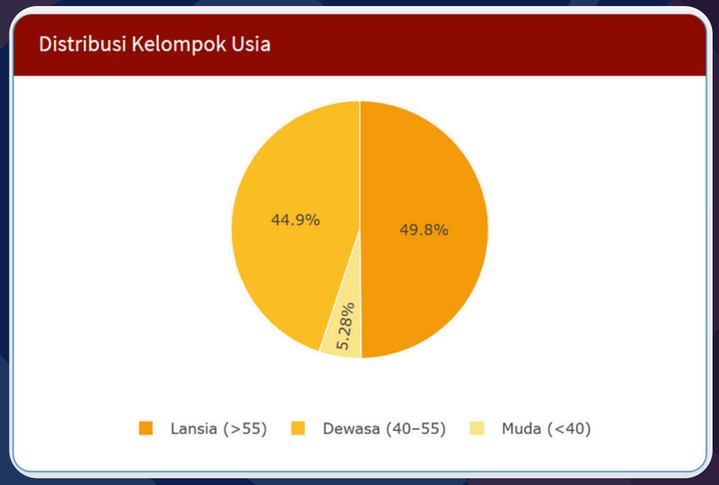
54.5%
Persentase Penyakit Jantung

54.4
Rata-rata Usia

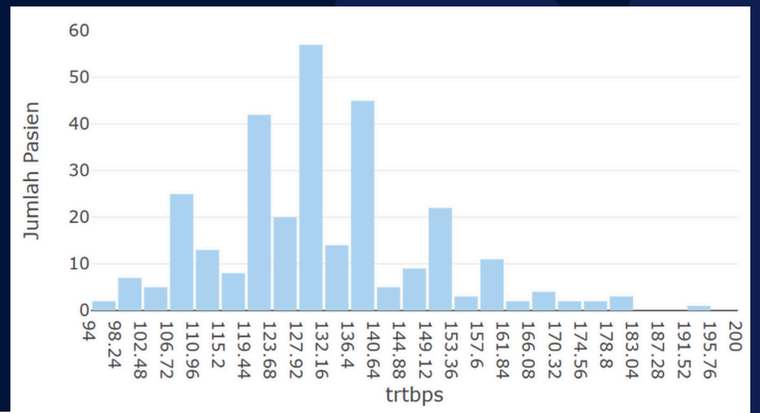
68.3%
Dominasi Laki-laki

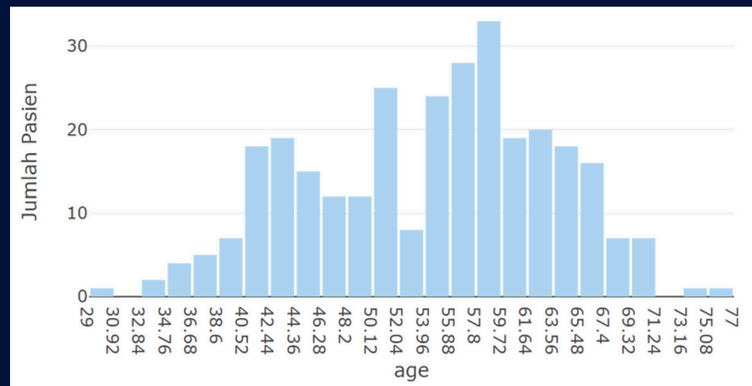


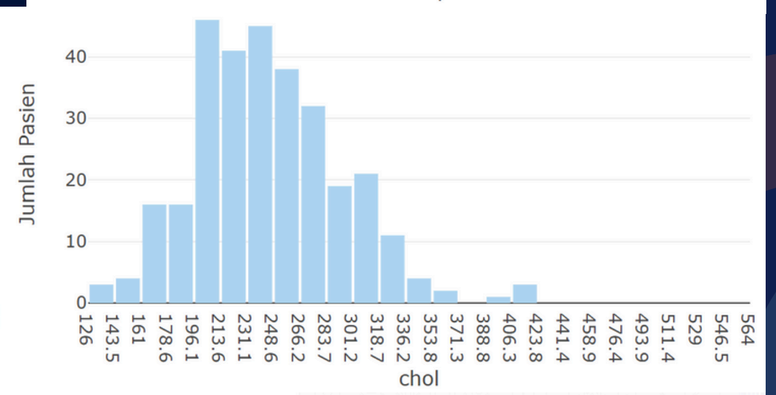


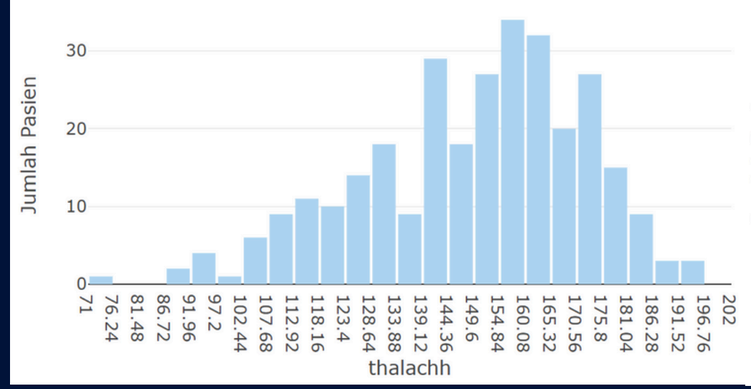


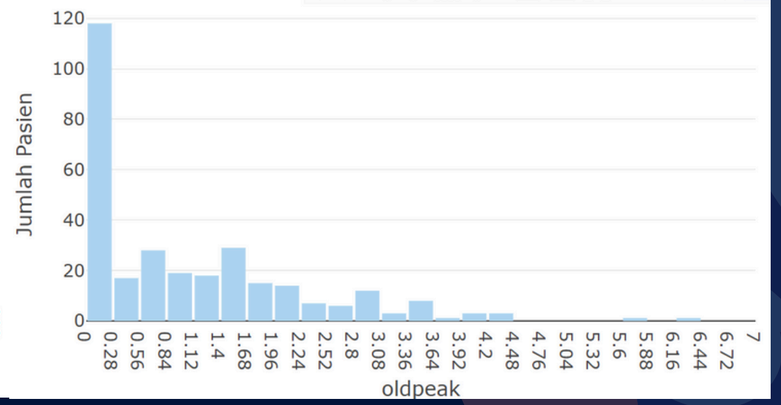
SUMMARY STATISTICS & VISUALIZATION





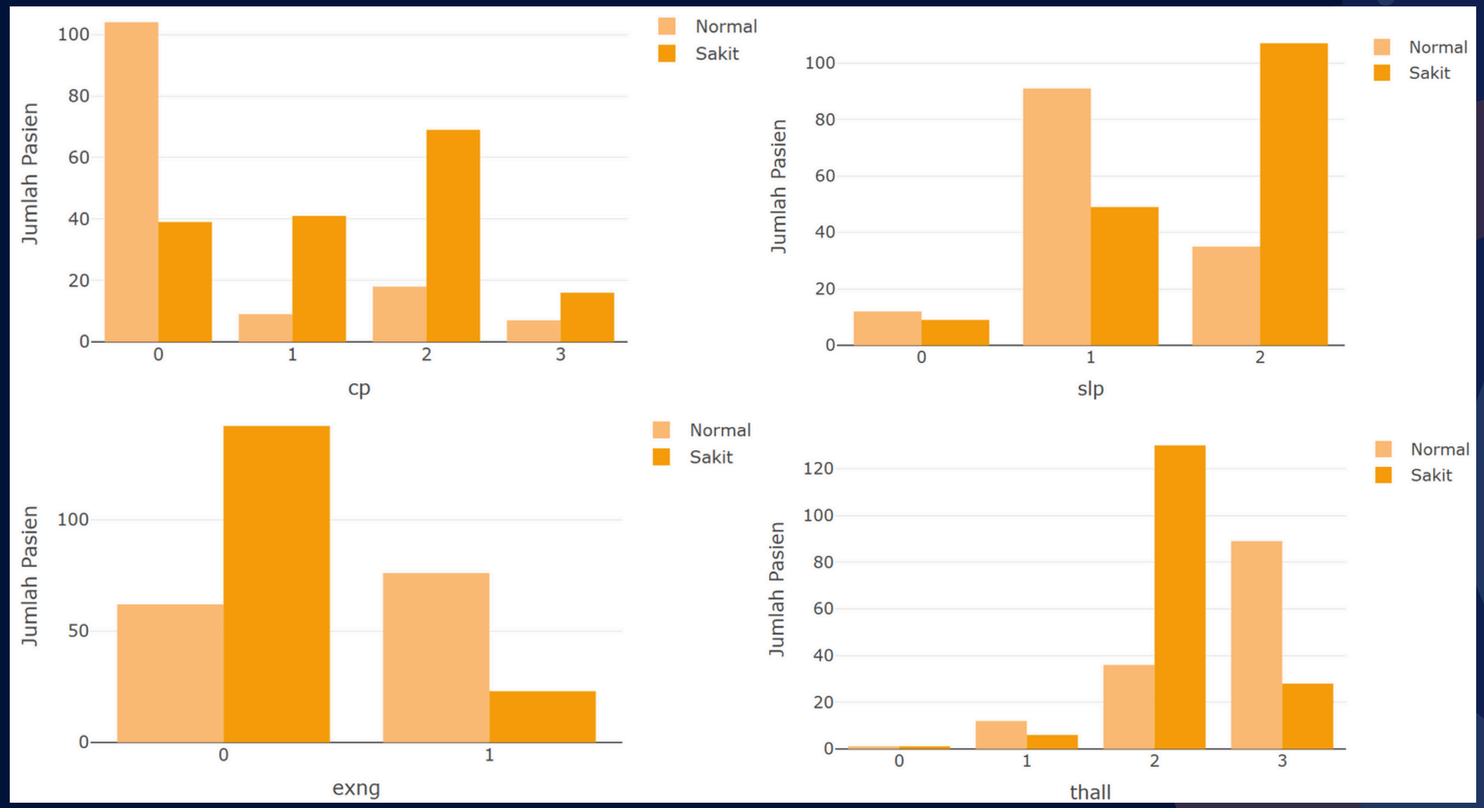






Mayoritas variabel seperti **age, chol, dan thalach** menunjukkan distribusi yang **relatif normal**, sedangkan **trestbps** masih tampak **cukup menyebar** dengan beberapa nilai ekstrem, dan **oldpeak** memiliki distribusi yang **tidak normal (sangat skewed)** dengan mayoritas berada pada nilai rendah

SUMMARY STATISTICS & VISUALIZATION

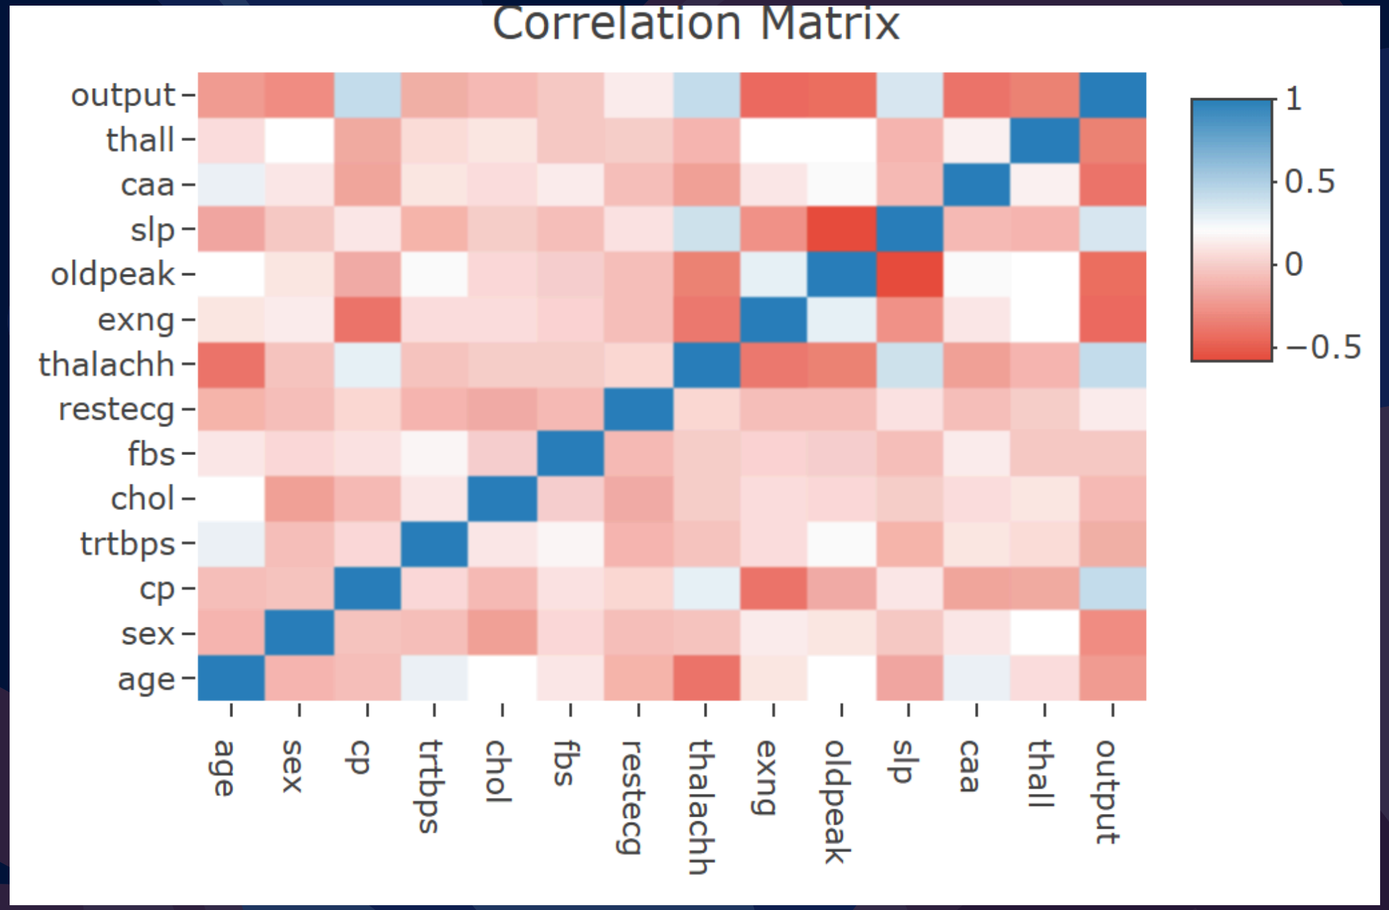


Variabel kategorikal menunjukkan bahwa kategori tertentu pada cp, slp, dan thall lebih sering muncul pada pasien yang sakit dibandingkan yang normal, sehingga ketiganya tampak cukup kuat membedakan kondisi pasien.

Sedangkan exng justru menunjukkan pola yang kurang konsisten karena pasien sakit lebih banyak berada pada kategori tanpa angina saat olahraga, sehingga variabel ini terlihat kurang stabil sebagai indikator tunggal.

SUMMARY STATISTICS & VISUALIZATION

Correlation matrix menunjukkan bahwa output paling berkorelasi adalah thal, caa, slp, oldpeak, dan exng, sementara variabel lain seperti chol, trestbps, dan fbs memiliki korelasi lemah, sehingga fitur-fitur utama yang paling berpengaruh adalah lima variabel tersebut.



FEATURE SELECTION

Urutan fitur paling penting

	Feature	F-Score	P-Value
20	thall_2	109.370527	2.458776e-21
21	thall_3	86.566924	8.780840e-18
12	exng_1	61.310002	1.563446e-13
4	oldpeak	59.359001	3.451658e-13
14	slp_2	55.947792	1.397167e-12
3	thalachh	51.814467	7.785557e-12
13	slp_1	41.118881	7.541216e-10
7	cp_2	33.783379	1.951195e-08
16	caa_2	16.888403	5.443879e-05
5	sex_1	15.924171	8.762457e-05
6	cp_1	14.067594	2.211315e-04
15	caa_1	11.955537	6.444087e-04
0	age	11.790474	7.011676e-04
17	caa_3	10.388675	1.443775e-03
10	restecg_1	8.858233	3.216110e-03
2	chol	4.703977	3.107540e-02
1	trtbps	4.616888	3.265950e-02
19	thall_1	4.078165	4.455249e-02
8	cp_3	2.279299	1.324265e-01
11	restecg_2	1.428622	2.331692e-01
18	caa_4	1.330543	2.498562e-01
9	fbs_1	0.327369	5.677480e-01

Memilih fitur yang signifikan (p-value < 0.05), selain itu tidak digunakan lagi dalam analisis

Fitur yang tidak signifikan

8	cp_3
11	restecg_2
18	caa_4
9	fbs_1

Fitur yang dipertahankan

20	thall_2
21	thall_3
12	exng_1
4	oldpeak
14	slp_2
3	thalachh
13	slp_1
7	cp_2
16	caa_2
5	sex_1
6	cp_1
15	caa_1
0	age
17	caa_3
10	restecg_1
2	chol
1	trtbps
19	thall_1

MODELING CLASSIFICATION

10 | KELOMPOK 7

- Random Forest -

```
Random Forest Accuracy: 0.7377049180327869

Classification Report:
              precision    recall  f1-score   support

       False       0.77      0.61      0.68        28
        True       0.72      0.85      0.78        33

    accuracy                           0.74        61
   macro avg       0.75      0.73      0.73        61
weighted avg       0.74      0.74      0.73        61


Confusion Matrix:
 [[17 11]
 [ 5 28]]
```

- **Akurasi model sebesar 74%.**
- **Model lebih baik mendeteksi pasien sakit (recall 85%) dibanding pasien normal (recall 61%).**
- **Precision cukup seimbang antara kedua kelas.**
- **Kesalahan terbesar = 11 pasien normal diprediksi sebagai sakit.**
- **Confusion matrix menunjukkan prediksi benar: 17 normal dan 28 sakit.**

Secara umum model sudah baik, tapi perlu peningkatan untuk mengenali pasien normal.

- Logistic Regression -

```
Logistic Regression Accuracy: 0.8360655737704918

Classification Report:
              precision    recall  f1-score   support

       False       0.85      0.79      0.81        28
        True       0.83      0.88      0.85        33

    accuracy                           0.84        61
   macro avg       0.84      0.83      0.83        61
weighted avg       0.84      0.84      0.84        61


Confusion Matrix:
 [[22  6]
 [ 4 29]]
```

- Akurasi model mencapai **84%**, lebih tinggi dari Random Forest.
- Model seimbang dalam mendeteksi kedua kelas, dengan **recall 79% (normal) dan 88% (sakit)**.
- **Precision kedua kelas juga baik**, yaitu 85% (normal) dan 83% (sakit).
- Confusion matrix menunjukkan prediksi benar: **22 pasien normal dan 29 pasien sakit.**
- Kesalahan relatif kecil: **hanya 6 pasien normal diprediksi sakit dan 4 pasien sakit diprediksi normal.**

Secara keseluruhan, Logistic Regression memberikan performa lebih stabil dan lebih akurat dibanding model sebelumnya.

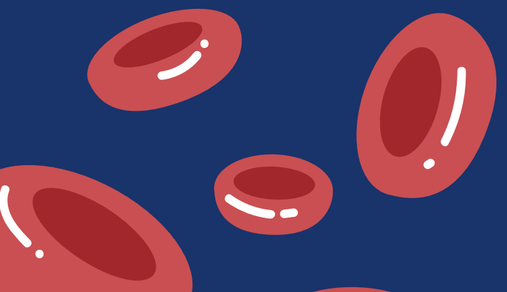
11 KELOMPOK 7

MODELING CLASSIFICATION

- K-Means Clustering -

```
KMeans Accuracy: 0.7491749174917491
```

- Akurasi model sebesar **75%**.
- Model mampu mengelompokkan pasien cukup baik, tetapi lebih rendah dibanding Logistic Regression (84%).
- Cocok untuk eksplorasi pola data, tapi kurang andal untuk prediksi pasien individual dibanding model supervised.



TRAINING-TESTING

Repeated Holdout

Random Forest

```
Rata-rata Akurasi (10x repeated holdout): 0.7623
Standar Deviasi: 0.0601
```

Logistic Regression

```
Rata-rata Akurasi (10x repeated holdout): 0.8115
Standar Deviasi: 0.0588
```

Regresi Logistik lebih baik daripada Random Forest

- Akurasinya lebih tinggi (81.15% vs 76.23%).
- Variasinya sedikit lebih rendah → lebih stabil.

Secara keseluruhan, Model Regresi Logistik menunjukkan performa yang lebih akurat dan lebih konsisten, sehingga lebih cocok untuk digunakan pada kasus prediksi serangan jantung ini.

TRAINING-TESTING

K-Fold Cross Validation

Random Forest

```
CV Mean Accuracy: 0.8116939890710382
CV Std: 0.033526004129778 28
```

Logistic Regression

```
CV Mean Accuracy: 0.8579234972677595
CV Std: 0.0313058006091711 7
```

Cross Validation untuk K-Means

K-Means

```
Silhouette Score Mean: 0.17748206
Silhouette Score Std: 0.00216224 2
```

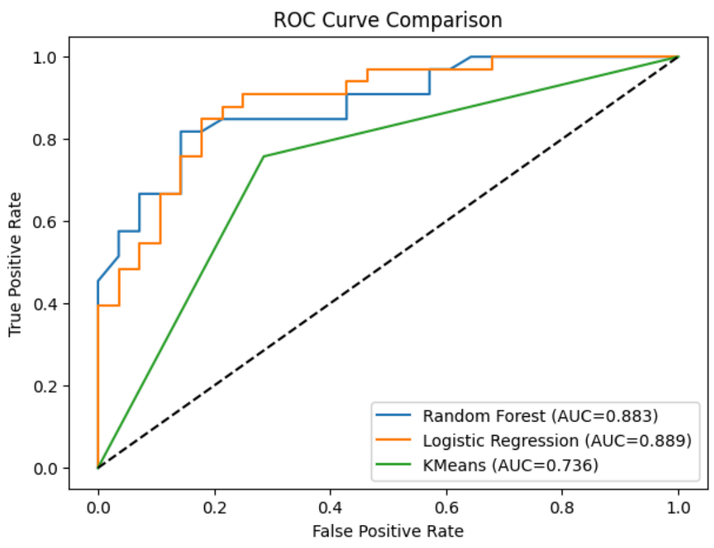
- Hasil cross-validation menunjukkan bahwa Logistic Regression memiliki performa paling stabil dan akurat dibanding Random Forest.
- Untuk model clustering, nilai rata-rata Silhouette Score sebesar 0.1775 dengan standar deviasi 0.0021 menunjukkan bahwa kualitas pengelompokan masih tergolong lemah atau kurang jelas.

MODEL PERFORMANCE COMPARISON

```
=== Random Forest ===
Akurasi      : 0.7377
Sensitivitas : 0.8485
Spesifisitas : 0.6071
AUC          : 0.8831
```

```
=== Logistic Regression ===
Akurasi      : 0.8361
Sensitivitas : 0.8788
Spesifisitas : 0.7857
AUC          : 0.8885
```

```
=== KMeans (Cluster to Class) ===
Akurasi      : 0.7377
Sensitivitas : 0.7576
Spesifisitas : 0.7143
AUC          : 0.7359
```



Dari evaluasi tiga model yaitu Random Forest, Logistic Regression, dan KMeans terlihat bahwa **supervised learning (Random Forest dan Logistic Regression) memberikan akurasi lebih tinggi** dibanding unsupervised (KMeans).

Logistic Regression memiliki performa terbaik dan paling seimbang, dengan akurasi, sensitivitas, spesifisitas, dan AUC tertinggi, sehingga mampu mendeteksi pasien sakit secara andal sekaligus meminimalkan false positive.

KESIMPULAN

- Logistic Regression menunjukkan performa terbaik dengan akurasi rata-rata sekitar 85.79%, menandakan bahwa model mampu mengidentifikasi pasien berisiko tinggi secara konsisten.
- Analisis fitur mengungkap bahwa faktor yang paling memengaruhi risiko adalah hasil pemeriksaan thallium stress test (baik abnormal maupun sangat abnormal), munculnya angina saat aktivitas fisik, nilai ST depression (oldpeak), serta perubahan slope segmen ST.

LINK R-SHINY

https://ruthwahyu5.shinyapps.io/DashboardDatmin/

DEMO R-SHINY

https://drive.google.com/file/d/1_2qtpHNsamCPgEZ41XusPTYOuFt6KPfZ/view?usp=drive_link

THANK YOU FOR ATTENTION

SEE YOU NEXT PRESENTATION

